

Tổng quan nghiên cứu cho bài toán gợi ý OTTO

Kiều Hồng Phong

3 tháng 4 năm 2026

Tóm tắt

OTTO có thể được xem là một bài toán gợi ý quy mô lớn, ẩn danh, dựa trên phiên, với ba đầu ra dự đoán gồm click, cart và order, thay vì cá nhân hóa dựa trên lịch sử đầy đủ của người dùng [1, 2]. Về mặt học thuật, bài toán này gần nhất với session-based recommendation, nhưng không thể được giải thích đầy đủ nếu chỉ đặt trong khung dự đoán item tiếp theo theo nghĩa hẹp. Cấu trúc nhân click/cart/order làm phát sinh đồng thời hai chiều phân tích: thứ nhất là mô hình hóa nhiều loại hành vi với cường độ ý định khác nhau; thứ hai là tối ưu nhiều mục tiêu xếp hạng có thể hỗ trợ hoặc cạnh tranh lẫn nhau. Vì vậy, OTTO nằm ở giao điểm của session-based recommendation, sequential recommendation, graph-based recommendation, Transformer-based recommendation, multi-objective recommendation và multi-behavior recommendation.

Các mô hình phiên sâu giai đoạn đầu như GRU4Rec đặt nền tảng cho việc biểu diễn ý định ngắn hạn từ chuỗi tương tác ẩn danh [3, 4]. Các hướng mở rộng dựa trên đồ thị và self-attention cho thấy khả năng biểu diễn tốt hơn đối với chuyển tiếp phi tuyến và phụ thuộc dài hạn [5, 6]. Tuy nhiên, khi chuyển sang bối cảnh công nghiệp như OTTO, năng lực biểu diễn không phải là tiêu chí duy nhất. Các công trình gần đây về Transformer cho gợi ý theo phiên cho thấy hiệu quả thực nghiệm còn phụ thuộc mạnh vào negative sampling, loss design và tổ chức pipeline truy hồi-xếp hạng [7]. Đồng thời, các nghiên cứu về tối ưu đa mục tiêu và gợi ý đa hành vi cho thấy việc đồng nhất clicks, carts và orders vào một mục tiêu duy nhất là chưa đầy đủ về mặt phương pháp luận [8, 9, 10, 11]. Từ đó, OTTO có thể được định vị như một benchmark công nghiệp khó không chỉ vì quy mô dữ liệu, mà còn vì yêu cầu kết hợp mô hình hóa phiên ngắn, dị biệt hành vi, tối ưu đa mục tiêu và khả năng mở rộng triển khai.

1 Giới thiệu

OTTO có thể được phát biểu như một bài toán dự đoán item tiếp theo hoặc tiếp diễn phiên, trong đó mô hình quan sát một chuỗi sự kiện ẩn danh trong một phiên mua sắm và cần dự đoán những item nào có khả năng sẽ được click, thêm vào giỏ hàng hoặc đặt mua tiếp theo [1, 2]. Phát biểu này

cho thấy OTTO chia sẻ lỗi bài toán với session-based recommendation: thông tin duy nhất sẵn có là chuỗi tương tác ngắn hạn trong một phiên, không phải hồ sơ dài hạn của người dùng. Tuy nhiên, khác với nhiều benchmark session-based chuẩn chỉ dự đoán một loại tương tác hoặc một nhân mục tiêu, OTTO yêu cầu dự đoán đồng thời ba loại hành vi có mức độ cam kết khác nhau. Vì vậy, bài toán không chỉ là dự đoán theo phiên, mà còn là bài toán học trên chuỗi phiên với cấu trúc nhân không đồng nhất.

Sự khác nhau giữa session-based recommendation và sequential recommendation có ý nghĩa trực tiếp đối với việc định vị OTTO. Session-based recommendation thường giả định dữ liệu bị ràng buộc trong các phiên ngắn, người dùng ẩn danh hoặc không có hồ sơ bền vững, và mục tiêu là suy ra ý định nhất thời từ ngữ cảnh cục bộ [12]. Sequential recommendation, ngược lại, thường giả định có lịch sử người dùng kéo dài qua thời gian và khai thác trật tự tương tác để học sở thích tiến hóa ở cấp độ người dùng [6]. OTTO gần với session-based recommendation hơn vì đơn vị suy luận là phiên ẩn danh. Tuy nhiên, OTTO vẫn hưởng lợi từ sequential modeling vì bản thân chuỗi sự kiện trong phiên là có thứ tự, và ý định tại thời điểm cuối phiên có thể phụ thuộc vào các mẫu phụ thuộc xa hơn là chỉ các tương tác liền kề. Nói cách khác, session-based và sequential không loại trừ nhau trong bối cảnh OTTO; khác biệt chủ yếu nằm ở giả định dữ liệu, trong khi nhiều cơ chế mô hình hóa chuỗi của sequential recommendation vẫn có thể chuyển giao sang thiết lập theo phiên.

Bộ dữ liệu công khai và tài liệu của cuộc thi mô tả OTTO như một benchmark thương mại diện tử trong thế giới thực dành cho hệ gợi ý dựa trên phiên, hỗ trợ dự đoán clicks, carts và orders [1, 2]. Cách định nghĩa này làm nảy sinh một điểm khác biệt quan trọng giữa benchmark học thuật chuẩn và benchmark công nghiệp. Trong các benchmark học thuật, mục tiêu thường được cô đọng thành bài toán dự đoán item tiếp theo với không gian ứng viên và yêu cầu suy luận được kiểm soát hơn. Trong OTTO, bài toán gần hơn với một pipeline công nghiệp, trong đó mô hình không chỉ cần biểu diễn chính xác ý định phiên mà còn phải hỗ trợ truy hồi và xếp hạng trong không gian item lớn, với các mục tiêu đánh giá tách biệt theo từng loại hành động [7]. Chính sự kết hợp này khiến OTTO khó hơn một benchmark tuần tự hoặc theo phiên thông thường.

Từ góc nhìn phương pháp luận, OTTO nằm ở giao điểm của ba lớp vấn đề. Lớp thứ nhất là biểu diễn ngữ cảnh phiên ngắn trong điều kiện không có thông tin người dùng dài hạn. Lớp thứ hai là mô hình hóa cấu trúc nhân click/cart/order như các tín hiệu vừa liên hệ vừa không đồng nhất. Lớp thứ ba là tối ưu các mục tiêu xếp hạng trong một hệ thống có ràng buộc về khả năng mở rộng, lấy mẫu âm và sinh ứng viên. Do đó, một mô tả đầy đủ về OTTO cần đồng thời sử dụng ngôn ngữ của session-based recommendation, sequential modeling, multi-behavior learning và multi-objective optimization.

2 Tổng quan nghiên cứu

2.1 Các phương pháp truyền thống

Các hệ gợi ý truyền thống chủ yếu được xây dựng trên lọc cộng tác, lọc dựa trên nội dung và các phương pháp lai, trong đó matrix factorization từng giữ vai trò baseline phổ biến nhờ hiệu quả tính toán và hiệu năng thực nghiệm tốt. Bài toán mà nhánh nghiên cứu này thực sự giải quyết là suy ra sở thích người dùng tương đối ổn định từ ma trận tương tác người dùng-mặt hàng, thường trong

điều kiện dữ liệu thưa nhưng có danh tính người dùng được duy trì. Giả định cốt lõi ở đây là sở thích có thể được tóm tắt thành các biểu diễn tĩnh hoặc gần tĩnh, và việc bỏ qua thứ tự tương tác không làm mất đi phần lớn tín hiệu dự báo.

Ưu điểm của hướng truyền thống là khả năng mở rộng tốt, diễn giải tương đối rõ ràng và sự phù hợp tự nhiên với các pipeline retrieval-ranking. Các ý tưởng như học từ implicit feedback, tối ưu các hàm mất mát định hướng ranking và phân tách truy hồi với xếp hạng vẫn có giá trị đối với OTTO. Tuy nhiên, hạn chế phương pháp luận của hướng này cũng là lý do dẫn tới sự hình thành của session-based recommendation: khi mục tiêu là nắm bắt ý định ngắn hạn từ chuỗi tương tác ẩn danh, các biểu diễn sở thích tĩnh hoặc tổng hợp theo người dùng trở nên không đủ. Đối với OTTO, vấn đề không nằm ở việc thiếu tín hiệu tương tác, mà nằm ở chỗ tín hiệu đó chỉ tồn tại trong một ngữ cảnh phiên ngắn và biến đổi nhanh. Vì vậy, hướng truyền thống cung cấp nền tảng cho tư duy retrieval và ranking, nhưng không mô tả đầy đủ bản chất động, cục bộ và đa hành vi của bài toán.

2.2 Gợi ý dựa trên phiên

Session-based recommendation ra đời nhằm khắc phục hạn chế của các phương pháp phụ thuộc vào danh tính người dùng và lịch sử dài hạn. Bài toán trung tâm của nhánh này là dự đoán hành vi tiếp theo từ một chuỗi tương tác ngắn, thường ẩn danh, trong đó tín hiệu quan trọng nhất là động lực ngắn hạn thay vì sở thích dài hạn [12]. Giả định cốt lõi của hướng này là một phiên có thể cung cấp đủ ngữ cảnh để suy ra ý định nhất thời, và ý định đó thường được phản ánh mạnh ở các tương tác gần thời điểm hiện tại.

GRU4Rec là công trình tiêu biểu cho bước chuyển từ các heuristic và mô hình Markov sang biểu diễn sâu cho chuỗi phiên [3]. Điểm mạnh của hướng RNN trong session-based recommendation là khả năng mã hóa trực tiếp thứ tự sự kiện và cập nhật trạng thái phiên tuần tự theo thời gian. Công trình top- k gains tiếp tục làm rõ rằng đối với bài toán session recommendation, hiệu quả không chỉ phụ thuộc vào bộ mã hóa chuỗi mà còn phụ thuộc vào việc mục tiêu huấn luyện có được căn chỉnh với metric xếp hạng hay không [4]. Điều này đặc biệt phù hợp với OTTO, nơi mục tiêu đánh giá cũng là ranking-based.

Tuy nhiên, hạn chế phương pháp luận của session-based recommendation truyền thống cũng khá rõ. Thứ nhất, nhiều mô hình giả định một dòng sự kiện đồng nhất và chỉ tối ưu một mục tiêu dự đoán duy nhất. Thứ hai, cấu trúc tuần tự thuần túy thường nén toàn bộ phiên vào một trạng thái ẩn, do đó khó biểu diễn các chuyển tiếp phi tuyến, các lần quay lại item hoặc các mẫu phụ thuộc xa trong chuỗi. Thứ ba, phần lớn benchmark session-based chuẩn không phản ánh đầy đủ bối cảnh truy hồi quy mô lớn và cấu trúc nhân đa hành vi như trong OTTO. Vì vậy, session-based recommendation là khung gần nhất với OTTO về mặt giả định dữ liệu, nhưng chưa đủ để bao quát bài toán nếu chỉ dừng ở dạng RNN đơn mục tiêu.

2.3 Gợi ý tuần tự

Sequential recommendation giải quyết một bài toán khác với session-based recommendation, dù hai hướng có chung việc sử dụng thứ tự tương tác. Trọng tâm của sequential recommendation là

học sở thích người dùng từ lịch sử có thứ tự kéo dài theo thời gian, thường với giả định rằng người dùng có danh tính ổn định và các tương tác trong quá khứ xa hơn vẫn mang tín hiệu dự báo cho tương lai [6]. Do đó, bài toán mà nhánh này thực sự giải quyết là mô hình hóa sự tiến hóa của sở thích ở cấp độ người dùng, chứ không chỉ ý định cục bộ trong một phiên.

SASRec thể hiện rõ giá trị phương pháp luận của hướng này: self-attention cho phép mô hình học phụ thuộc dài hạn giữa các vị trí trong chuỗi mà không phải đi qua một chuỗi cập nhật trạng thái tuần tự như RNN [6]. Điều này mang lại hai hệ quả. Một mặt, expressive power tăng lên vì mô hình có thể cân nhắc các tương tác ở nhiều khoảng cách khác nhau. Mặt khác, tính song song trong huấn luyện và suy luận được cải thiện. Đối với OTTO, các ưu điểm này là hữu ích vì ý định hiện tại trong phiên có thể phụ thuộc vào nhiều tín hiệu rời rạc trong chuỗi, không chỉ vào tương tác liền kề cuối cùng.

Tuy nhiên, mức độ tương thích giữa sequential recommendation và OTTO chỉ là một phần. Các mô hình sequential thường được đánh giá trên dữ liệu có lịch sử người dùng dài hơn, nơi quan hệ giữa tương tác hiện tại và quá khứ xa mang ý nghĩa khác với quan hệ trong một phiên ngắn. Khi chuyển sang OTTO, nhiều giả định này không còn đúng: không có hồ sơ người dùng ổn định, chân trời quan sát ngắn hơn và mục tiêu dự đoán không còn là một nhãn đơn nhất. Vì vậy, sequential recommendation cung cấp cơ chế mô hình hóa chuỗi hữu ích cho OTTO, nhưng không cung cấp trực tiếp khung phát biểu bài toán. Đây là lý do OTTO gần với session-based recommendation hơn, dù vẫn hưởng lợi đáng kể từ các ý tưởng của sequential modeling.

2.4 Gợi ý theo phiên dựa trên đồ thị

Graph-based session recommendation xuất hiện để khắc phục một giới hạn cụ thể của các mô hình chuỗi thuần túy: chuỗi tuyến tính không phải lúc nào cũng là biểu diễn đầy đủ cho cấu trúc chuyển tiếp trong phiên. Trong nhiều bối cảnh thương mại điện tử, người dùng có thể lặp lại click, quay lại các item đã xem, hoặc di chuyển giữa các nhánh sản phẩm liên quan. Bài toán mà nhánh này thực sự giải quyết là biểu diễn cấu trúc chuyển tiếp phi tuyến trong phiên, thay vì chỉ ghi nhận thứ tự tuyến tính của các sự kiện.

SR-GNN là công trình tiêu biểu cho hướng này khi mô hình hóa mỗi phiên như một đồ thị có hướng và áp dụng graph neural message passing để học biểu diễn phiên [5]. Giả định cốt lõi của phương pháp là cấu trúc chuyển tiếp item-to-item trong phiên chứa thông tin mà mô hình chuỗi tuyến tính có thể làm mờ đi. Điểm mạnh phương pháp luận của graph-based models là khả năng biểu diễn đồng thời các quan hệ lặp lại, rẽ nhánh và kết nối không cục bộ trong phiên. Đây là một ưu thế phù hợp với OTTO, bởi hành vi duyệt sản phẩm trong thương mại điện tử thường không tuân theo một đường đi đơn giản.

Đổi lại, expressive power cao hơn đi kèm với chi phí xây dựng và xử lý đồ thị lớn hơn. Ngoài ra, khi biến chuỗi thành đồ thị, thông tin thời gian tuyệt đối hoặc tương đối có thể bị suy giảm nếu không được thiết kế bổ sung. Trong bối cảnh OTTO, đây là một trade-off quan trọng: graph-based models phù hợp hơn với hành vi duyệt phi tuyến, nhưng không tự động giải quyết các yêu cầu về nhiều loại hành vi, nhiều mục tiêu xếp hạng và khả năng truy hồi ở quy mô lớn. Khoảng trống còn bỏ ngỏ là cách kết hợp lợi thế cấu trúc của đồ thị với ràng buộc về khả năng mở rộng và với cơ chế học có nhận thức loại hành động.

2.5 Gợi ý theo phiên và tuần tự dựa trên Transformer

Transformer trở thành một nhánh nổi bật trong recommender systems vì giải quyết đồng thời hai hạn chế của RNN: nút thắt tuần tự trong tính toán và khả năng biểu diễn hạn chế đối với phụ thuộc dài hạn [6]. Bài toán mà nhánh này nhắm tới là học quan hệ giữa nhiều vị trí trong chuỗi một cách linh hoạt hơn, đồng thời hỗ trợ huấn luyện song song. Khi được chuyển sang bối cảnh session recommendation, mục tiêu là giữ lại lợi thế biểu diễn của self-attention nhưng thích ứng với chuỗi ngắn, không gian item lớn và ràng buộc huấn luyện ở quy mô công nghiệp.

TRON cho thấy điểm mạnh của Transformer trong gợi ý theo phiên không thể tách rời khỏi training recipe [7]. Công trình này làm rõ rằng performance của mô hình không chỉ là hệ quả của kiến trúc self-attention, mà phụ thuộc mạnh vào negative sampling, loss design và tổ chức huấn luyện. Điều này có hệ quả phương pháp luận trực tiếp đối với OTTO. Trong benchmark công nghiệp, nơi không gian ứng viên rất lớn và mục tiêu đánh giá tập trung vào top- k , mô hình mạnh về biểu diễn nhưng yếu về cơ chế lấy mẫu hoặc mục tiêu học có thể không chuyển hóa được thành hiệu quả xếp hạng thực tế.

Do đó, Transformer-based recommendation có hai ưu điểm chính đối với OTTO. Thứ nhất, mô hình có thể học được phụ thuộc không cục bộ trong chuỗi phiên tốt hơn RNN. Thứ hai, nó phù hợp với các thiết kế retrieval-ranking hiện đại, nơi encoder cần đủ linh hoạt để tái sử dụng ở nhiều cấu hình huấn luyện và suy luận. Tuy nhiên, hạn chế của hướng này là chi phí tính toán cao, độ nhạy đối với thiết kế huấn luyện và việc chưa mặc nhiên giải quyết bài toán đa mục tiêu hay đa hành vi. Nói cách khác, Transformer mạnh ở biểu diễn chuỗi, nhưng không tự nó giải quyết cấu trúc nhân click/cart/order. Đây là lý do vì sao trong OTTO, lựa chọn kiến trúc cần đi kèm với lựa chọn training objective và pipeline sinh ứng viên.

2.6 Gợi ý đa mục tiêu

Multi-objective recommendation nghiên cứu các tình huống mà hệ thống cần tối ưu đồng thời nhiều mục tiêu có thể tương hợp hoặc xung đột [8]. Bài toán mà nhánh này giải quyết khác về bản chất với multi-behavior recommendation. Ở đây, trọng tâm không phải là mô hình hóa dị biệt của các loại hành động như một cấu trúc dữ liệu, mà là học các nghiệm đánh đổi giữa nhiều mục tiêu tối ưu, ví dụ giữa click-through, conversion hoặc các lợi ích của các bên liên quan khác nhau. Giả định cốt lõi của nhánh này là không phải lúc nào cũng tồn tại một mục tiêu vô hướng duy nhất phản ánh đầy đủ yêu cầu của hệ thống.

Trong OTTO, clicks, carts và orders có thể được xem như các mục tiêu dự đoán riêng biệt vì mỗi loại hành động có ý nghĩa và mức độ quan trọng khác nhau. Điều này làm cho weighted-sum objective trở thành một lựa chọn thực dụng nhưng không phải lúc nào cũng đủ. Một hàm mất mát vô hướng có thể trộn lẫn các tín hiệu khác biệt về bản chất và làm cho mô hình ưu tiên các hành vi xuất hiện dày đặc hơn, trong khi làm mờ các mục tiêu hiếm hơn nhưng có giá trị cao hơn. MultiTRON đưa ra một phản hồi trực tiếp cho vấn đề này bằng cách xem gợi ý theo phiên như một bài toán tối ưu Pareto, trong đó mô hình học một họ nghiệm đánh đổi thay vì ép toàn bộ mục tiêu vào một điểm tối ưu duy nhất [9].

Ưu điểm của góc nhìn multi-objective là nó mô tả đúng hơn bản chất của OTTO ở cấp độ tối ưu hóa. Tuy nhiên, hạn chế là chi phí huấn luyện, tinh chỉnh và triển khai thường lớn hơn so với thiết kế weighted-sum đơn giản. Ngoài ra, multi-objective recommendation không trả lời trực tiếp câu hỏi cách biểu diễn chuỗi phiên hay cách mô hình hóa loại hành vi. Vì vậy, đây là một góc nhìn bổ sung chứ không thay thế cho session-based hoặc multi-behavior modeling. Khoảng trống còn bỏ ngỏ là cách kết hợp tối ưu đa mục tiêu với một bộ mã hóa phiên có khả năng mở rộng và với một pipeline truy hồi-xếp hạng phù hợp cho môi trường công nghiệp.

2.7 Gợi ý đa hành vi

Multi-behavior recommendation tập trung vào việc mô hình hóa nhiều loại tương tác của người dùng, chẳng hạn click, cart và purchase, như những tín hiệu không đồng nhất về mức độ ý định [10, 11]. Bài toán mà nhánh này thực sự giải quyết là làm thế nào tận dụng được quan hệ giữa các hành vi có cường độ khác nhau để cải thiện chất lượng dự đoán, thay vì coi mọi tương tác là tương đương. Giả định cốt lõi là các loại hành vi khác nhau mang giá trị giám sát khác nhau và cấu trúc phụ thuộc giữa chúng có thể được khai thác như một nguồn thông tin bổ sung.

Đây là lý do multi-behavior recommendation gần với OTTO ở bình diện ngữ nghĩa hơn cả multi-objective recommendation. OTTO chứa chính ba loại hành vi phổ biến trong thương mại điện tử: clicks, carts và orders. Tuy nhiên, hai góc nhìn này không đồng nhất. Multi-behavior tập trung vào biểu diễn dữ liệu và quan hệ giữa các tín hiệu hành vi; multi-objective tập trung vào cách tối ưu nhiều mục tiêu đánh giá hoặc kinh doanh. Một hệ thống có thể là multi-behavior mà không tối ưu Pareto, và cũng có thể là multi-objective mà không mô hình hóa tường minh cấu trúc hành vi. Đối với OTTO, cả hai góc nhìn đều cần thiết vì clicks/carts/orders vừa là các loại hành vi khác nhau, vừa là các mục tiêu xếp hạng tách biệt.

Hạn chế lớn nhất của văn liệu multi-behavior khi áp dụng vào OTTO là giả định dữ liệu. Nhiều nghiên cứu trong nhánh này giả định có danh tính người dùng ổn định và lịch sử dài hạn, qua đó cho phép mô hình học quan hệ giữa các hành vi trong phạm vi thời gian dài hơn [10, 11]. OTTO, ngược lại, bị ràng buộc bởi phiên ngắn và ẩn danh. Vì vậy, thách thức không chỉ là mô hình hóa loại hành vi, mà là mô hình hóa nó trong điều kiện ngữ cảnh ngắn và không có hồ sơ người dùng bền vững. Khoảng trống nghiên cứu vì thế nằm ở việc đưa các ý tưởng của multi-behavior learning vào một thiết lập session-based có khả năng mở rộng, thay vì chỉ chuyển nguyên mô hình từ bối cảnh user-level sang.

3 Các công trình tiêu biểu

3.1 Từ mô hình tuần tự thuần túy đến biểu diễn phiên có cấu trúc

GRU4Rec, top- k gains và SR-GNN có thể được đọc như ba bước phát triển liên tiếp trong cùng một trục phương pháp luận. GRU4Rec thiết lập giả định rằng ý định trong phiên có thể được nén thành một trạng thái chuỗi học được và tối ưu trực tiếp cho bài toán xếp hạng [3]. Công trình top- k gains không thay đổi giả định biểu diễn cốt lõi, nhưng sửa một điểm yếu quan trọng của hướng

RNN ban đầu: mục tiêu huấn luyện cần bám sát metric đánh giá hơn để hiệu năng top- k phản ánh đúng chất lượng retrieval [4]. SR-GNN tiếp tục đẩy hướng này thêm một bước bằng cách thay đổi bản thân đối tượng biểu diễn: thay vì xem phiên như một chuỗi tuyến tính, nó xem phiên như một đồ thị chuyển tiếp [5].

Điểm khác nhau giữa ba công trình không chỉ nằm ở kiến trúc, mà ở giả định về cấu trúc dữ liệu. GRU4Rec và top- k gains giả định trật tự tuyến tính là đủ để nắm bắt phần lớn tín hiệu. SR-GNN giả định rằng cấu trúc chuyển tiếp phi tuyến mới là phần bị bỏ sót quan trọng nhất. Trong bối cảnh OTTO, cả hai giả định đều có giá trị nhưng không hoàn chỉnh. Chuỗi tuyến tính phù hợp với việc khai thác recency và trật tự thời gian, trong khi biểu diễn đồ thị phù hợp hơn với hành vi duyệt lặp lại hoặc rẽ nhánh. Vì vậy, giá trị của các công trình này đối với OTTO nằm ở việc cho thấy bài toán không chỉ là chọn một kiến trúc tốt hơn, mà là chọn giả định dữ liệu phù hợp hơn.

3.2 Từ self-attention trong sequential recommendation đến Transformer theo phiên ở quy mô công nghiệp

SASRec và TRON cũng tạo thành một cặp đối chiếu có ý nghĩa. SASRec chứng minh rằng self-attention là một lựa chọn mạnh mẽ cho bài toán dự đoán item tiếp theo trong dữ liệu có thứ tự [6]. Điểm mạnh của công trình là mở rộng expressive power của mô hình chuỗi và giảm bớt hạn chế tính toán của RNN. Tuy nhiên, SASRec chủ yếu được định vị trong bối cảnh sequential recommendation, nơi lịch sử người dùng dài hơn và mục tiêu thường là single-label next-item prediction.

TRON giữ lại lợi thế biểu diễn của Transformer nhưng chuyển trọng tâm sang các điều kiện mà benchmark công nghiệp như OTTO phải đối mặt: không gian item lớn, đánh giá top- k , yêu cầu huấn luyện hiệu quả và ràng buộc truy hồi thực tế [7]. Giá trị phương pháp luận của TRON không chỉ nằm ở việc dùng Transformer cho dữ liệu phiên, mà ở việc cho thấy hiệu năng của Transformer phụ thuộc mạnh vào negative sampling và loss design. So với SASRec, TRON dịch chuyển trọng tâm từ kiến trúc nào tốt hơn sang kiến trúc đó phải được huấn luyện như thế nào để có ích trong môi trường công nghiệp. Đối với OTTO, đây là một dịch chuyển quan trọng vì benchmark không chỉ kiểm tra khả năng biểu diễn chuỗi mà còn gián tiếp kiểm tra khả năng gắn kết giữa mô hình và pipeline retrieval-ranking.

3.3 Từ tối ưu một mục tiêu đến tối ưu nhiều mục tiêu và nhiều hành vi

Khảo sát về multi-objective recommender systems, MultiTRON và các khảo sát về multi-behavior recommendation đại diện cho một trục phát triển khác, không xoay quanh kiến trúc biểu diễn mà xoay quanh cách phát biểu bài toán [8, 9, 10, 11]. Multi-objective recommender systems đặt câu hỏi về việc hệ thống cần tối ưu cái gì khi tồn tại nhiều mục tiêu có thể xung đột. MultiTRON cụ thể hóa câu hỏi này trong bối cảnh session-based recommendation bằng một cách tiếp cận Pareto-aware [9]. Trong khi đó, các khảo sát về multi-behavior recommendation đặt câu hỏi khác: cần biểu diễn dữ liệu như thế nào khi các loại tương tác không đồng nhất về ý nghĩa và cường độ [10, 11].

Điểm đối chiếu quan trọng ở đây là multi-objective và multi-behavior giải quyết hai mặt khác nhau của cùng một hiện tượng. Multi-objective mạnh ở mức tối ưu hóa, nhưng không tự động cung cấp

cơ chế học quan hệ giữa các loại hành vi. Multi-behavior mạnh ở mức biểu diễn tín hiệu, nhưng không tự động đảm bảo rằng các mục tiêu đánh giá được cân bằng phù hợp. Đối với OTTO, việc chỉ sử dụng một trong hai góc nhìn thường dẫn đến thiếu hụt: hoặc mô hình hiểu được dị biệt hành vi nhưng tối ưu hóa chưa phản ánh đúng trade-off, hoặc mô hình tối ưu nhiều mục tiêu nhưng coi dữ liệu hành vi như các nhãn độc lập đơn giản.

4 Bảng so sánh các công trình chính

Công trình	Năm	Họ phương pháp	Đóng góp chính	Hạn chế và mức liên quan đến OTTO
GRU4Rec [3]	2016	RNN	Mô hình hóa phiên như chuỗi sự kiện bằng GRU; thiết lập baseline sâu cho session-based recommendation	Nút thắt tuần tự và mô hình hóa hành vi còn hạn chế; mức liên quan rất cao vì phù hợp trực tiếp với phiên ẩn danh
Top- k Gains [4]	2018	RNN + ranking loss	Căn chỉnh mục tiêu huấn luyện với metric ranking top- k	Vẫn là luồng đơn và mục tiêu đơn; mức liên quan rất cao vì OTTO đánh giá theo ranking
SASRec [6]	2018	Transformer	Đưa self-attention vào dự đoán item tiếp theo với huấn luyện song song hiệu quả	Cần lịch sử đủ dài và chưa nhận thức hành vi; mức liên quan cao như một họ mô hình tham chiếu
SR-GNN [5]	2019	GNN	Biểu diễn phiên bằng đồ thị để mô hình hóa chuyển tiếp phi tuyến	Chi phí đồ thị cao và chưa xử lý đa mục tiêu; mức liên quan cao với các phiên có item lặp lại
Survey on Session-based RS [12]	2021	Survey	Taxonomy cho các phương pháp theo phiên và thảo luận benchmark	Không phải bài báo phương pháp; mức liên quan cao như tài liệu nền
Multi-objective RS Survey [8]	2022	Survey / theory	Tổng quan các mục tiêu cạnh tranh trong hệ gợi ý	Không trực tiếp đề xuất mô hình cho OTTO; mức liên quan cao ở bình diện khái niệm
TRON [7]	2023	Transformer	Cải thiện hiệu quả huấn luyện Transformer cho gợi ý theo phiên thông qua negative sampling và loss design	Phụ thuộc benchmark và đa mục tiêu không phải trọng tâm; mức liên quan rất cao ở quy mô công nghiệp
MultiTRON [9]	2024	Pareto optimization	Xấp xỉ Pareto front cho gợi ý theo phiên đa mục tiêu	Khó tinh chỉnh và triển khai; mức liên quan rất cao vì phù hợp trực tiếp với clicks, carts và orders
Survey on Multi-Behavior Sequential Recommendation [10]	2026	Survey	Taxonomy cho mô hình hóa tuần tự có nhận thức hành vi	Thường giả định người dùng cố định; mức liên quan cao vì OTTO có tín hiệu đa hành vi
Comprehensive Survey on Multi-Behavior RS [11]	2026	Survey	Taxonomy mở rộng cho recommender systems đa hành vi	Ít đặc thù cho OTTO hơn; mức liên quan từ trung bình đến cao

Bảng 1: So sánh các công trình tiêu biểu

5 Khoảng trống nghiên cứu và các thách thức

OTTO khác với nhiều benchmark học thuật chuẩn ở ba tầng đồng thời. Ở tầng dữ liệu, benchmark này ẩn danh và bị ràng buộc theo phiên, làm giảm mức độ áp dụng trực tiếp của các phương pháp dựa trên lịch sử người dùng dài hạn [1, 2]. Ở tầng nhân, OTTO không chỉ yêu cầu dự đoán một tương tác kế tiếp, mà yêu cầu xử lý đồng thời clicks, carts và orders như các tín hiệu có cường độ và giá trị khác nhau. Ở tầng hệ thống, OTTO vận hành trong bối cảnh công nghiệp, nơi không gian item lớn, việc lấy mẫu, sinh ứng viên và độ trễ suy luận trở thành các ràng buộc thiết kế bậc nhất [7]. Chính tổ hợp của ba tầng này làm cho OTTO khó hơn một benchmark tuần tự hoặc session-based chuẩn.

Khoảng trống thứ nhất của văn liệu hiện tại nằm ở sự không khớp giữa giả định dữ liệu và giả định mục tiêu. Session-based recommendation phù hợp với dữ liệu của OTTO nhưng thường được phát biểu như bài toán single-objective. Multi-behavior recommendation phù hợp với cấu trúc hành vi của OTTO nhưng thường giả định có người dùng ổn định và lịch sử dài hạn [10, 11]. Multi-objective recommendation phù hợp với cách phát biểu bài toán tối ưu nhưng không tự động trả lời cách biểu diễn chuỗi phiên hoặc quan hệ giữa các loại hành vi [8, 9]. Vì vậy, thách thức không nằm ở việc chọn một nhánh nghiên cứu duy nhất, mà ở việc kết hợp các giả định tương thích của nhiều nhánh trong cùng một hệ thống.

Khoảng trống thứ hai là trade-off giữa expressive power và scalability. RNN-based session models có chi phí tính toán tương đối thuận lợi nhưng bị giới hạn bởi nút thắt tuần tự và khả năng biểu diễn cấu trúc chuyển tiếp phức tạp. Graph-based models tăng năng lực biểu diễn đối với hành vi duyệt phi tuyến, nhưng chi phí xây dựng và xử lý đồ thị lớn hơn [5]. Transformer-based models mạnh ở biểu diễn phụ thuộc xa và thích hợp với self-attention, nhưng hiệu quả của chúng phụ thuộc chặt vào training recipe, negative sampling và loss design, đồng thời chi phí triển khai cao hơn [6, 7]. OTTO làm cho trade-off này trở nên rõ ràng hơn, vì benchmark không chỉ thưởng cho mô hình có biểu diễn tốt mà còn gián tiếp thưởng cho thiết kế có khả năng vận hành trong một pipeline truy hồi thực tế.

Khoảng trống thứ ba liên quan trực tiếp đến cấu trúc nhân click/cart/order. Trong OTTO, ba nhân này vừa là các hành vi khác nhau, vừa là các mục tiêu xếp hạng khác nhau. Vì vậy, việc sử dụng một weighted-sum objective đơn giản có thể là điểm khởi đầu hợp lý nhưng chưa chắc đủ để phản ánh đúng cấu trúc của bài toán. Nếu trọng số không được lựa chọn phù hợp, mô hình có thể thiên lệch về các tín hiệu phổ biến hơn và làm mờ những mục tiêu hiếm hơn nhưng có giá trị dự báo hoặc kinh doanh cao hơn [8, 9]. Nói cách khác, khó khăn của OTTO không chỉ đến từ quy mô dữ liệu mà còn đến từ việc phải duy trì sự phân biệt giữa các mục tiêu hành động trong khi vẫn học được các quan hệ hỗ trợ lẫn nhau giữa chúng.

Khoảng trống thứ tư là vai trò của retrieval-ranking pipeline. Trong nhiều benchmark học thuật, bài toán thường được trình bày như dự đoán trực tiếp trên một tập ứng viên được kiểm soát. Trong môi trường gần công nghiệp như OTTO, hiệu năng của hệ thống phụ thuộc không chỉ vào encoder mà còn vào cách sinh ứng viên, cách lấy mẫu âm và cách tổ chức khâu reranking [7]. Điều này có nghĩa là một mô hình mạnh về mặt biểu diễn nhưng khó tích hợp vào pipeline truy hồi quy mô lớn có thể không phải là lựa chọn thực dụng nhất. Khoảng trống nghiên cứu do đó không chỉ là “mô hình nào chính xác hơn”, mà là “mô hình nào duy trì được chất lượng xếp hạng khi được đặt vào

kiến trúc retrieval-ranking có ràng buộc thực tế”.

Từ góc nhìn này, các hướng lai như shared session encoder kết hợp với behavior-specific heads, pipeline hai giai đoạn retrieval-reranking, hoặc mô hình kết hợp graph/Transformer với loss định hướng top- k là những lựa chọn phù hợp cho OTTO [5, 7, 9]. Tuy nhiên, mức độ phù hợp ở đây cần được hiểu một cách dè dặt: các hướng này mới chỉ cho thấy sự tương thích về mặt phương pháp luận, chứ chưa loại bỏ được hoàn toàn các trade-off giữa năng lực biểu diễn, khả năng tối ưu nhiều mục tiêu và chi phí triển khai.

6 Các tài liệu nền được ưu tiên

Một bộ tài liệu nền gọn cho bài toán này có thể bắt đầu từ các công trình về session-based recommendation của Hidasi và cộng sự [3, 4], mô hình graph-based của Wu và cộng sự [5], mô hình self-attention của Kang và McAuley [6], khảo sát về session-based recommendation [12], khảo sát về multi-objective recommender systems [8], các khảo sát về multi-behavior recommendation [10, 11], cùng với tài liệu mô tả bộ dữ liệu và benchmark OTTO [1, 2]. Đối với các hướng gần với bối cảnh triển khai thực tế của OTTO, TRON và MultiTRON cung cấp hai tham chiếu trực tiếp cho Transformer theo phiên và tối ưu đa mục tiêu trong môi trường công nghiệp [7, 9].

7 Related Work

Session-based recommendation là điểm xuất phát tự nhiên nhất để định vị OTTO, vì benchmark này yêu cầu suy ra ý định từ các phiên mua sắm ngắn và ẩn danh thay vì từ hồ sơ người dùng dài hạn [1, 2, 12]. Điểm cốt lõi của hướng nghiên cứu này là giả định rằng ngữ cảnh phiên chứa đủ tín hiệu để dự đoán hành động tiếp theo trong một chân trời ngắn. Các mô hình đầu tiên như GRU4Rec khai thác giả định này bằng cách mã hóa chuỗi phiên theo kiểu hồi tiếp và tối ưu trực tiếp cho ranking [3]. Công trình top- k gains sau đó cho thấy trong bài toán gợi ý theo phiên, việc căn chỉnh mục tiêu học với metric đánh giá là một thành phần phương pháp luận quan trọng không kém lựa chọn kiến trúc [4]. Tuy nhiên, phần lớn văn liệu session-based truyền thống vẫn phát biểu bài toán dưới dạng dự đoán một dòng sự kiện đồng nhất, do đó chưa phản ánh đầy đủ cấu trúc nhân click/cart/order của OTTO.

Sequential recommendation có giao điểm với OTTO ở mức cơ chế mô hình hóa, nhưng không đồng nhất với OTTO ở mức giả định dữ liệu. Các phương pháp sequential thường giả định có lịch sử người dùng kéo dài và học phụ thuộc theo thứ tự ở cấp độ người dùng. SASRec là công trình tiêu biểu cho hướng này khi sử dụng self-attention để mô hình hóa phụ thuộc dài hạn trong chuỗi [6]. Đối với OTTO, giá trị của sequential recommendation không nằm ở cách phát biểu bài toán, mà ở việc cung cấp các cơ chế biểu diễn mạnh hơn cho chuỗi sự kiện. Điều này đặc biệt hữu ích khi ý định tại cuối phiên phụ thuộc vào nhiều tương tác phân tán trong chuỗi. Tuy nhiên, sự không tương thích vẫn còn rõ: OTTO là benchmark theo phiên, ẩn danh và đa nhân, trong khi nhiều benchmark sequential chuẩn là user-level và single-label.

Graph-based session recommendation xuất hiện để giải quyết một giới hạn của các mô hình chuỗi

thuần túy: trật tự tuyến tính không luôn đủ để mô tả hành vi duyệt thực tế. SR-GNN cho thấy khi phiên được xem như một đồ thị chuyển tiếp, mô hình có thể biểu diễn tốt hơn các lần quay lại item, các nhánh chuyển đổi và các quan hệ không cục bộ trong phiên [5]. Điều này làm cho graph-based models có ý nghĩa đặc biệt đối với OTTO, nơi hành vi duyệt sản phẩm có thể phi tuyến. Tuy nhiên, lợi thế biểu diễn đi kèm với chi phí tính toán cao hơn và với câu hỏi chưa được giải quyết đầy đủ về cách duy trì thông tin thời gian và khả năng mở rộng trong một pipeline truy hồi công nghiệp.

Transformer-based recommendation mở rộng hướng sequential modeling bằng một giả định mạnh hơn về expressive power của self-attention. Khi được chuyển sang bối cảnh session recommendation, hướng nghiên cứu này cho thấy khả năng mô hình hóa phụ thuộc xa tốt hơn RNN và thuận lợi hơn về mặt song song hóa. Tuy nhiên, các công trình gần với bối cảnh OTTO cho thấy kiến trúc không phải là toàn bộ câu chuyện. TRON nhấn mạnh rằng trong môi trường session-based công nghiệp, hiệu quả của Transformer phụ thuộc mạnh vào negative sampling, loss design và cách tổ chức huấn luyện [7]. Vì vậy, điểm mạnh của Transformer trong OTTO không thể được đánh giá chỉ từ năng lực biểu diễn chuỗi; nó phải được đánh giá trong mối liên hệ với retrieval-ranking pipeline và với chi phí triển khai trên không gian ứng viên lớn.

Một trục phương pháp luận khác là multi-objective recommendation. Góc nhìn này đặc biệt phù hợp với OTTO vì benchmark yêu cầu dự đoán ba loại đích có ý nghĩa xếp hạng riêng. Văn liệu về multi-objective recommender systems chỉ ra rằng trong nhiều bối cảnh, việc gộp các mục tiêu vào một scalar objective duy nhất có thể làm mất đi cấu trúc đánh đổi thực sự của bài toán [8]. MultiTRON cụ thể hóa lập luận này cho session-based recommendation bằng một cơ chế Pareto-aware, thay vì chỉ dùng weighted-sum [9]. Điều này phù hợp với OTTO khi clicks, carts và orders không chỉ khác nhau về tần suất mà còn khác nhau về ý nghĩa. Tuy nhiên, multi-objective optimization không tự động giải quyết cách biểu diễn chuỗi phiên hay cách học quan hệ giữa các hành vi, và chi phí triển khai của các phương pháp Pareto thường cao hơn.

Multi-behavior recommendation bổ sung một góc nhìn khác cho OTTO. Nếu multi-objective tập trung vào câu hỏi cần tối ưu cái gì, thì multi-behavior tập trung vào câu hỏi cần mô hình hóa dữ liệu như thế nào khi các loại tương tác không đồng nhất [10, 11]. Văn liệu này cho thấy clicks, carts và purchases không nên bị đồng nhất hóa thành cùng một loại tín hiệu, vì chúng mang cường độ ý định khác nhau. Đây là một quan sát trực tiếp áp dụng được cho OTTO. Tuy nhiên, phần lớn các mô hình multi-behavior được xây dựng trên giả định có người dùng ổn định và lịch sử dài hạn, nên việc chuyển trực tiếp sang thiết lập theo phiên còn gặp khó khăn. Do đó, khoảng trống trung tâm của OTTO nằm ở việc kết hợp ba yêu cầu vốn thường được xử lý riêng rẽ trong văn liệu: biểu diễn ý định phiên ngắn, mô hình hóa dị biệt hành vi và tối ưu nhiều mục tiêu trong điều kiện truy hồi quy mô lớn.

Tổng hợp lại, OTTO nằm tại giao điểm của session-based recommendation, sequential modeling, graph representation learning, multi-objective optimization và multi-behavior prediction. Vì vậy, hướng tiếp cận phù hợp nhất không phải là mở rộng một nhánh đơn lẻ, mà là phối hợp các giả định tương thích từ nhiều nhánh. Cụ thể, benchmark này đòi hỏi một bộ mã hóa phiên đủ mạnh để khai thác thứ tự và cấu trúc chuyển tiếp, một cơ chế học đủ linh hoạt để duy trì sự phân biệt giữa clicks, carts và orders, và một pipeline retrieval-ranking đủ hiệu quả để vận hành trong không gian ứng viên lớn [5, 7, 9, 10, 11]. Chính yêu cầu đồng thời trên cả ba phương diện này làm cho OTTO trở thành một benchmark có giá trị học thuật và thực tiễn.

8 Kết luận

OTTO có thể được định vị như một bài toán gợi ý theo phiên đa hành vi và đa mục tiêu trong bối cảnh thương mại điện tử quy mô lớn. Các hướng nghiên cứu về session-based recommendation, sequential recommendation, graph neural recommendation, Transformer-based recommendation, multi-objective recommendation và multi-behavior recommendation đều đóng góp những thành phần lý thuyết cần thiết để tiếp cận bài toán này. Tuy nhiên, mỗi nhánh chỉ giải quyết tốt một phần vấn đề: session-based recommendation phù hợp với dữ liệu phiên ẩn danh; sequential modeling cung cấp cơ chế học phụ thuộc có thứ tự; graph-based models tăng năng lực biểu diễn cho chuyển tiếp phi tuyến; Transformer-based models mở rộng expressive power nhưng phụ thuộc mạnh vào training recipe; multi-objective recommendation làm rõ cấu trúc tối ưu; còn multi-behavior recommendation làm rõ cấu trúc tín hiệu hành vi.

Do đó, khó khăn của OTTO không chỉ nằm ở quy mô dữ liệu, mà ở việc phải kết hợp các quyết định biểu diễn, tối ưu hóa và triển khai trong cùng một hệ thống. Giá trị học thuật của benchmark này nằm ở chỗ nó buộc người nghiên cứu phải vượt ra ngoài các phát biểu bài toán một nhánh, và xem recommender system như một bài toán giao thoa giữa mô hình hóa chuỗi theo phiên, học trên tín hiệu hành vi không đồng nhất, tối ưu đa mục tiêu và thiết kế retrieval-ranking có khả năng mở rộng.

Tài liệu

- [1] P. Normann, S. Baumeister, and T. Wilm, “OTTO Recommender Systems Dataset: A real-world e-commerce dataset for session-based recommender systems research,” Kaggle Dataset, 2023. [Online]. Available: <https://www.kaggle.com/dsv/4991874>
- [2] OTTO Group, “OTTO Recommender System Challenge Overview,” Kaggle Competition Overview, 2022. [Online]. Available: <https://www.kaggle.com/competitions/otto-recommender-system/overview>
- [3] B. Hidasi, A. Karatzoglou, L. Baltrunas, and D. Tikk, “Session-based recommendations with recurrent neural networks,” in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2016. [Online]. Available: <https://arxiv.org/abs/1511.06939>
- [4] B. Hidasi and A. Karatzoglou, “Recurrent neural networks with top-k gains for session-based recommendations,” in *Proceedings of the 27th ACM International Conference on Information and Knowledge Management (CIKM)*. ACM, 2018, pp. 843–852. [Online]. Available: <https://dl.acm.org/doi/10.1145/3269206.3271761>
- [5] S. Wu, Y. Tang, Y. Zhu, L. Wang, X. Xie, and T. Tan, “Session-based recommendation with graph neural networks,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 33, no. 1, 2019, pp. 346–353. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/3804>
- [6] W.-C. Kang and J. McAuley, “Self-attentive sequential recommendation,” in *2018 IEEE International Conference on Data Mining (ICDM)*. IEEE, 2018, pp. 197–206. [Online]. Available: <https://ieeexplore.ieee.org/document/8594844>

- [7] T. Wilm, P. Normann, S. Baumeister, and P.-V. Kobow, “Scaling session-based transformer recommendations using optimized negative sampling and loss functions,” in *Proceedings of the 17th ACM Conference on Recommender Systems*. ACM, 2023, pp. 1023–1026. [Online]. Available: <https://dl.acm.org/doi/10.1145/3604915.3610236>
- [8] Y. Zheng and D. X. Wang, “A survey of recommender systems with multi-objective optimization,” *Neurocomputing*, vol. 474, pp. 141–153, 2022. [Online]. Available: <https://doi.org/10.1016/j.neucom.2021.11.041>
- [9] T. Wilm, P. Normann, and F. Stepprath, “Pareto front approximation for multi-objective session-based recommender systems,” in *Proceedings of the 18th ACM Conference on Recommender Systems*. ACM, 2024, pp. 809–812. [Online]. Available: <https://dl.acm.org/doi/10.1145/3640457.3688048>
- [10] X. Chen, Z. Li, W. Pan, Q. Yang, and Z. Ming, “A survey on multi-behavior sequential recommendation,” *Science China Information Sciences*, vol. 69, p. 131101, 2026. [Online]. Available: <https://doi.org/10.1007/s11432-024-4568-7>
- [11] K. Kim, S. Kim, G. Lee, J. Jung, and K. Shin, “A comprehensive survey on multi-behavior recommender systems: Extended taxonomy and recent advances,” *International Journal of Data Science and Analytics*, vol. 22, p. 40, 2026. [Online]. Available: <https://doi.org/10.1007/s41060-025-01019-z>
- [12] S. Wang, L. Cao, Y. Wang, Q. Z. Sheng, M. A. Orgun, and D. Lian, “A survey on session-based recommender systems,” *ACM Computing Surveys*, vol. 54, no. 7, pp. 154:1–154:38, 2021. [Online]. Available: <https://doi.org/10.1145/3465401>